

Uma verdadeira Epistemologia para a Inteligência Artificial (Versão Revisada)

Por Daniel Barros Fonseca

Filósofo, Escritor e jornalista investigativo

Criador da IA Doninha

Vale dizer que a ideia para escrever este artigo surgiu de uma conversa com uma inteligência artificial (grok) em que as respostas não passavam de alucinações malucas. Engraçadas, é claro, mas, ainda sim alucinações de máquina.

O objetivo deste artigo é apresentar uma reflexão sobre o modelo adotado pelas Big Techs para a programação dos Grandes Modelos de Linguagem e apontar a sua limitação – comprovada pelo alto número de alucinações de máquina – e propor um modelo híbrido de programação de LLMs baseado numa junção da Teoria do Juízo Kantiana e Lógica paraconsistente (através da lógica Difusa). A proposta deste artigo pode ser resumida nisto: um modelo de LLM híbrido que não se resume à meros cálculos estatísticos.

Devo agradecer ao professor Maikel Yelandi Leyva Vázquez por ter revisado a primeira versão deste artigo e me dado um norte tanto para revisa-lo quanto para a estruturação de um modelo de inteligência artificial baseado nesta proposta. Também devo agradecimento ao cientista de dados do fórum HuggingFace John666.

Aos que estão familiarizados com o debate atual dos LLMs, a proposta que defendo, aqui, é de um modelo neuro simbólico híbrido de LLM. Isto é, um modelo que tenha fundamentações epistemológicas de pré-processamento antes de cálculos de previsão do próximo token para gerar uma resposta em linguagem natural.

A atual limitação dos LLMs

O modelo atual de LLMs pode ser sintetizado da seguinte forma: dado um prompt a IA faz um cálculo matricial de previsão das próximas palavras que respondam ao que foi proposto no prompt. O modelo de negócios das Big Techs é o de que se uma LLM for grande o suficiente eventualmente iria atingir o santo graal da AGI. O problema desta

visão é que ela confunde a categoria da qualidade com a da quantidade – lembre-mo-nos do velho Aristóteles que já dizia que são coisas diferentes e uma não substitui a outra. Trata-se, portanto, de um modelo de negócios baseado numa falácia lógica.

Nas Refutações Sofísticas, Aristóteles identificou que a confusão de duas categorias como sendo a mesma coisa trata-se de uma falácia lógica. Dois predicados distintos não podem pertencer à mesma categoria. Isto é, o tamanho de uma rede neural, mesmo que artificial, não se confunde com a produção de inteligência. Fato este que é observável na biologia: o cérebro de uma baleia tem mais conexões neurais que o de um ser humano, mas, o ser humano é mais inteligente que uma baleia.

O problema das Big Techs está descrito naquela anedota do macaco e a máquina de escrever: dadas tentativas suficientes, um macaco apertando teclas aleatórias numa máquina de escrever eventualmente produzirá a própria *Ilíada*. As Big Techs baseiam seus negócios na falácia de que se fizerem algoritmos de cálculos estatísticos de previsão da próxima palavra complexos o suficiente surgirá, dali, uma inteligência artificial.

Talvez seja, apenas, engraçado que complexos com dezenas de milhares de engenheiros não conheçam Aristóteles para saber que é impossível surgir o entendimento a partir de meros cálculos estatísticos. Ah! Que falta faz um filósofo entre estes engenheiros!

O que é a proposta de uma verdadeira epistemologia para a Inteligência Artificial?

Não se pretende, aqui, dizer que a Inteligência Artificial irá sobrepujar a inteligência humana, mas, o de fornecer bases da Filosofia da Linguagem e da Filosofia da Lógica para que se estabeleça um paradigma novo para as inteligências artificiais. O que se pretende aqui é o de propor um modelo híbrido para as IAs que não sejam o mero cálculo estatístico, mas, o de estabelecer os verdadeiros limites para uma IA e propor um modelo de programação que tenha uma camada anterior aos cálculos estatísticos extraídos do treinamento de redes neurais artificiais.

A inteligência artificial jamais será inteligente, pois, esta é uma qualidade que surge de bilhões de anos de seleção natural e evolução dos seres biológicos. E jamais será artificial, pois, como ela não passa de um algoritmo, sempre precisará de alguém para programa-la. Ou, numa linguagem Aristotélica: o predicado de A não se confunde com o

predicado de B, isto é, a inteligência emergente dos seres biológicos não se confunde com a inteligência de máquinas digitais.

Já dizia Tomás de Aquino, relendo Aristóteles: a criatura não pode ser dotada de mais substância do que o seu próprio criador. E é isto que as Big Techs vendem como modelos de negócio: um computador mais inteligente que seu próprio criador. Certamente serve para especulação financeira este modelo de negócios, mas, no mundo real, não passa de uma falácia. Computadores até podem ser melhores em realizar algumas tarefas específicas que seres humanos, mas, nunca serão humanos ou formas de vidas artificiais. O que as Big Techs propõem é o mesmo sonho de pinóquio. Uma criatura que ganha vida própria e se torna humana. Uma pena para o modelo de negócios das Big Techs que não exista fada madrinha para realizar este sonho.

Um modelo Híbrido de IA: ou uma IA que não sonhe igual pinóquio

Desde os diálogos de velhice de Platão e, em especial, na filosofia da Linguagem de Russel é ponto quase pacífico de que a verdade é um atributo dos juízos de acordo com a identidade entre proposição e mundo real. Como computadores, IAs são meros algoritmos complexos, elas jamais poderão atribuir um valor verdade sobre o que existe e o que não existe no mundo real, pois, esta tarefa estará sempre sujeita ao que foi programado. Os engenheiros de IAs criaram uma boa solução para este problema, qual seja, o treinamento por reforço assistido. Mas, observe, caro leitor, que o valor verdade é obtido através da extrapolação estatística de um valor verdade dado por um ser humano.

O problema de se retirar o componente humano da atribuição do valor verdade é o mesmo que o de achar que um livro pode ler a si mesmo e ensinar a si mesmo o que aprendeu lendo a si mesmo. A Ciência utiliza testes duplo cegos para que não seja o mesmo autor que proponha o status de verdade científica à um estudo. Quem analisa um dado não pode ser o mesmo agente que propõe o dado. E esta limitação das IAs generativas atuais é que produz uma quantidade abismal de alucinações de máquina. É uma violação ao método científico: um valor verdade atribuído por si mesmo a si mesmo mediante complexos cálculos estatísticos.

A consequência lógica, incontornável e necessária desta limitação é o de que as IAs jamais atingirão o tão sonhado patamar de Inteligência Artificial Geral, pois, um algoritmo não passa de um algoritmo, isto é, a execução de uma determinada tarefa computacional a partir de um input que gera um output estatisticamente previsível. Isso se entendermos AGI como sendo uma inteligência super-humana. Minha proposta é que AGI seja entendida como uma espécie de interface remota entre cérebro e máquina. Isto é, uma ferramenta – muito útil – para expandir a capacidade humana para realizar determinadas tarefas.

Até aqui estabelecemos dois pontos chave deste modelo híbrido de IA: 1) o de que o tamanho da LLM não fará surgir a inteligência sobre humana e 2) a causa das alucinações de máquina estão no modelo de aprendizagem de máquina empregado pelas big techs, isto é, a aprendizagem por reforço de máquina é o que geram as alucinações de máquina, pois, caso se façam cálculos estatísticos preditivos da próxima palavra de uma proposição suficientemente grandes, pode-se chegar a qualquer proposição. Este segundo ponto ocorre devido a falta de um raciocínio epistêmico no processamento dos dados. A alucinação decorre da falha de identificação correta do contexto – isto é, do valor verdade (em termos da filosofia da linguagem).

Se o leitor já executou o mesmo prompt diversas vezes deve ter percebido que cada uma das vezes há uma resposta ligeiramente diferente. Isso acontece porque as IAs atuais são programadas para que em seus cálculos matriciais haja um certo grau de incerteza no output. Uma solução que parece ser boa, mas, é outro fator gerador de alucinações de máquina. Inevitavelmente este grau de incerteza adicionado propositalmente nos cálculos matriciais geram explosões lógicas não previstas pela mera predição matemática. O problema, em termos técnicos, é o de achar que lógica binária permitem graus de incerteza que não a mera atribuição de valores verdade que sejam distintos de “verdadeiro” ou “falso”. A linguagem é um sistema inconsistente, isto é, não linear. Neste sentido, toda a lógica de programação de uma IA deve ser a partir da lógica paraconsistente.

O ponto central para que as IAs sejam programadas a partir da lógica paraconsistente está na possibilidade de que se reduza o cálculo estatístico de predição da proposição numa trivialidade – isto é, num sistema trivial e inconsistente.

Em resumo, o problema de se utilizar a lógica binária num sistema de linguagem está na explosão lógica em que tudo é possível se inferir de tudo mediante uma mera operação de silogismo Aristotélico não científico.

Num exemplo prático. No prompt: “A água a 35 graus está quente ou fria?”. O cálculo matricial binário determinará que o algoritmo compare com seu banco de dados as proposições que dizem se a água está quente ou fria e, a partir disso, gere uma resposta que considera apenas o valor estatístico dado por uma análise combinatória sobre se 35 graus equivalem à “estar quente” ou “estar frio”. Este cálculo não permite que a resposta seja “à 35 graus a água está morna”, pois, o conceito de morno é um conceito contraditório que nos sistemas lógicos empregados pelas IAs atualmente gera uma explosão lógica (isto é, um convite à alucinação).

Vale um parêntesis, já enunciado anteriormente. A alucinação de máquina não decorre apenas de uma explosão lógica, mas, na falta de ferramentas das IAs para identificar quando um juízo não deve ser considerado verdadeiro ou falso, mas, incerto ou vago.

Algo estar “morno” é um valor verdade não permitido pela lógica binária, isto porque, é algo intermediário entre o valor verdade “absolutamente verdadeiro” e “absolutamente falso”, 0 ou 1. A abordagem paraconsistente, por outro lado, permite valores intermediários entre “absolutamente verdadeiro” e “absolutamente falso”. É possível, em programação, dizer que a água a 35 graus tem um valor verdade de 0,5 quente e 0,5 frio.

Ao contrário das IAs atuais, uma IA paraconsistente permite atribuir valores verdade não absolutos à uma proposição. A lógica paraconsistente é um modelo de lógica que não entra em colapso quando é dada uma proposição explosiva diante de uma contradição que só é contradição num sistema binário.

No exemplo dado acima, da água morna, um sistema binário colapsa ao tentar definir um valor verdade absoluto (necessariamente verdadeiro e necessariamente falso) ao tentar definir algo morno. Vale repetir, no sistema atual de IAs, só é permitido, dada a limitação da lógica binária, que a água esteja quente ou fria. O conceito de morno é impensável nesta lógica de computação binária.

Um exemplo ainda mais grave de que a forma de programação de lógica binária está na proposição: “Por que a água está fria à 20 graus, morna à 35 e quente à 50 graus?” O modelo de lógica binária de cálculo estatístico matricial não possui ferramentas matemáticas suficientes para responder perguntas do tipo “por que” ou cuja resposta demande uma análise de percepção subjetiva. O que as IAs atuais fazem é buscar em seu banco de dados proposições similares e a partir disso inferir uma resposta mediante um cálculo estatístico de equivalência entre prompt e algoritmo.

Esta limitação é outro convite para as alucinações, pois, a lógica clássica adotada pelas IAs pressupõe sistemas consistentes e livres de contradição. Este prompt de comparação entre diversas temperaturas, e que tem uma premissa escondida, qual seja, um juízo subjetivo, é uma contradição que gera explosão lógica no cálculo matricial estatístico do algoritmo preditivo da IA generativa.

Por “explosão lógica no cálculo matricial estatístico”, vale delimitar o meu argumento, entendo que há uma impossibilidade dos sistemas lógicos clássicos de identificar um valor intermediário entre verdadeiro e falso e, por isso, ao acessar o banco de dados para identificar o contexto (knowledge base ou KB) a IA opta por este ou aquele contexto ao qual se refere o prompt a partir do mero acaso (o que chamei de explosão lógica).

Outro fator que é um convite às alucinações de máquina gerada pela lógica binária clássica de cálculo matricial estatístico está no fato que o “reasoning” ou o que as big techs chamam, por vezes, de “Deep think” ou “think harder” está no fato de que este pensar profundo se baseia meramente na criação de hipóteses de resposta a partir de modelos de inferência focado no que Aristóteles chamou de “cópula” de uma premissa. O problema central está que nos sistemas de lógica clássica uma contradição trivializa o argumento.

O problema da lógica clássica é que mediante uma contradição ($A = 1$ e “não- A ” = 0) há a trivialização, isto é, para as IAs atuais toda premissa posterior é dedutível da premissa anterior. Ou seja, o modelo em que as IAs está programado define que a “próxima palavra” é definida por um cálculo estatístico de pertinência de comparação entre a “palavra anterior” e o banco de dados. As alucinações recorrentes dos modelos atuais de IA está no fato de que o mero cálculo estatístico torna qualquer proposição passível de ser tornada verdadeira. Por isso, prompts distintos podem gerar respostas

opostas e contraditórias. É a explosão lógica do sistema de inferência meramente estatístico. Fato que ocorre, vale frisar, pela incapacidade da lógica clássica de atribuir valores verdade intermediários ao absolutamente verdadeiro e ao absolutamente falso.

Vale notar que a lógica paraconsistente não persiste na negação do princípio de não contradição, mas, no refinamento das proposições contraditórias para que não gere trivialização da proposição e inferências absurdas provenientes de meros cálculos estatísticos matriciais de predição da próxima palavra do output trabalhado pelo algoritmo dado determinado prompt. O que quero dizer é que, num LLM, segundo uma lógica binária, as alucinações são recorrentes porque a linguagem consiste num modelo lógico não trivial em que a inconsistência é necessária de existir sem que gere uma explosão, tão logo, uma alucinação.

O problema das alucinações de máquina dos modelos atuais de IA é simples de se entender do ponto de vista lógico. O problema é que a linguagem é um sistema inconsistente, o que gera a trivialidade em que tudo é provável. E como os modelos atuais de IA se resumem ao cálculo de probabilidade estatística da próxima palavra mediante comparação com um banco de dados, a alucinação numa IA que usa o modelo binário de lógica clássica de cálculo estatístico matricial é inevitável e incontornável. Ou ainda, em outras palavras, o modelo atual de IA alucina, pois, ao tentar atribuir valores verdade para proposições de forma absoluta não permite o refinamento das proposições de tal forma que a explosão lógica é inevitável ao tentar se identificar o contexto adequado do prompt mediante a exposição de um banco de dados com informações incompletas ou contraditórias entre si. Em suma, os sistemas de lógica clássica que são usados na programação das IAs atuais, ao ser confrontado com uma contradição, trivializa o sistema de tal forma que toda proposição pode se tornar verdadeira – ou seja, uma alucinação.

Meu ponto central, aqui, é o de que falta um sistema de apuração do prompt e de identificação do contexto (KB) a partir de um sistema lógico que permita valores verdade intermediários entre o absolutamente verdadeiro e o absolutamente falso.

O ganho de se utilizar a lógica paraconsistente numa IA ou num LLM é o de que é possível computar “contradições locais” sem que isso gere “trivialidades globais”. No exemplo da água morna, não há contradição lógica em se atribuir valor verdade “verdadeiro” tanto para o conceito de quente quanto para o conceito de frio na lógica paraconsistente. Ou seja, há uma contradição local (quente e frio são conceitos opostos),

mas, não há uma trivialidade global – isto é, o conceito de morno é um refinamento da proposição de tal forma que a incerteza daquilo que é morno – dado que há uma subjetividade neste conceito – não gera explosão lógica na medida em que se atribui um valor verdade intermediário entre o que é “absolutamente verdadeiro”, ou 1, ou “absolutamente falso”, isto é, 0. Neste sentido, naquele exemplo que dei de uma comparação entre três temperaturas há uma atribuição de valores verdade intermediários para cada uma das temperaturas comparadas na proposição original sem que haja uma explosão lógica, mas, o que a lógica paraconsistente chama de explosão gentil.

Crítica da Inteligência Artificial Pura

Como argumentei acima, o problema dos modelos de IAs atuais está no seu modo de pensar em que toda inferência é possível (problema da trivialidade) dado seu modelo de funcionamento que é um mero cálculo estatístico de predição da próxima palavra de uma proposição. A universalidade da predição de palavras mediante inferências estatísticas é causa necessária e fundante das alucinações de máquina.

O primeiro passo para se evitar as alucinações de máquina está no que a lógica paraconsistente chamou de refinamento da proposição. Uma IA ao processar um prompt deve refinar este prompt de forma que seja possível buscar uma inferência que não seja mera equivalência de cálculo estatístico de comparação entre prompt e banco de dados. A forma de se evitar a trivialização está no refinamento do prompt na forma do que Aristóteles chamou de silogismo científico.

- **Regra dos Termos:** Deve conter apenas três termos (maior, menor e médio), cada um usado no mesmo sentido.
- **Regra do Termo Médio:** O termo médio nunca deve aparecer na conclusão.
- **Regra da Extensão:** Os termos na conclusão não podem ter uma extensão maior do que nas premissas.
- **Regra do Termo Médio Universal:** O termo médio deve ser universal (total) pelo menos uma vez nas premissas.
- **Regra das Negativas:** De duas premissas negativas, nada se conclui.

- **Regra das Afirmativas:** Duas premissas afirmativas devem resultar em uma conclusão afirmativa.
- **Regra das Particulares:** De duas premissas particulares, nada se conclui.
- **Regra da "Parte Fraca":** A conclusão segue sempre a premissa mais fraca, ou seja, se houver uma premissa negativa, a conclusão é negativa; se houver uma particular, a conclusão é particular.

Em certa medida já há o refinamento dos prompts na forma de silogismo científico aristotélico, contudo, o ponto central para que haja, no máximo, uma explosão gentil, no conceito da lógica paraconsistente, está na aplicação do paradoxo de Hempel. Diz o paradoxo:

A Lógica Indutiva: O princípio de que ver corvos pretos confirma que "todos os corvos são pretos" é intuitivo.

A Equivalência: Logicamente, a frase "Todos os corvos são pretos" é idêntica a "Tudo o que não é preto não é um corvo".

O Problema (Contra-intuitivo): Seguindo a lógica acima, ao ver uma maçã vermelha (que não é preta e não é um corvo), você está confirmando a segunda frase e, conseqüentemente, a primeira.

Conclusão: O paradoxo demonstra que a confirmação indutiva, baseada estritamente na lógica formal, pode levar a conclusões absurdas, pois objetos irrelevantes poderiam validar uma teoria científica.

Isto é, na lógica da LLM, nem toda palavra posterior pode ser inferida da palavra anterior. Quando uma LLM se baseia meramente em cálculos estatísticos preditivos ela está caindo na armadilha da intuição. A inconsistência de um sistema de linguagem meramente estatístico de predição da próxima palavra permite inferências que não passam de alucinação gerada por um cálculo de análise combinatória de probabilidade de palavras dado pelo banco de dados utilizado no treinamento da IA.

Se lembrarmos do paradoxo dos cisnes brancos e negros achamos um fio condutor para evitar esta armadilha dos sistemas triviais num contexto prático de LLM. Ao procurar a equivalência do silogismo científico aristotélico, a IA deve assumir que toda conclusão é falsa até que se encontre um exemplo verdadeiro. Ou seja, é falsa a proposição universal

de que todo cisne é branco, pois, podem existir cisnes negros. E porque toda premissa deve ser tomada como falsa até que se encontre um exemplo verdadeiro? Devido ao princípio da falseabilidade de Karl Popper.

Ao refinar o prompt em um silogismo científico aristotélico, portanto, a IA ao buscar uma equivalência com seu banco de dados deve procurar equivalências que são falseáveis e não valores verdade absolutos.

É preciso, sem mais, um sistema lógico que permita a identificação de proposições que sejam indeterminadas.

Se Kant, em *Crítica da Razão Pura* limitou o alcance da razão, isto é, o que é cognoscível pela razão, uma “Crítica da Inteligência Artificial Pura” não teria nenhum problema em limitar a aplicabilidade de uma inteligência artificial. Assim como a razão humana é limitada pela experiência sensível e pelas próprias estruturas mentais que organizam a realidade cognoscível para o humano, a IA estará sempre limitada pelo seu próprio algoritmo e a consequência necessária da limitação do que são operações computáveis e daquelas não computáveis. Uma IA estará sempre limitada, vale frisar, pelo seu algoritmo e pelo seu banco de dados. Ela estará sempre limitada ao seu próprio algoritmo e ao conhecimento usado para seu treinamento em seu banco de dados.

Em termos lógicos, e aqui agradeço novamente ao comentário do professor Maikel, há necessidade de diferenciar Verdade, Falsidade e incompletude. Isto é, no exemplo da água morna, o valor morno é um valor verdade intermediário gerado por um prompt incompleto. Cabe, como defendido acima, um sistema paraconsistente de refinamento da premissa que permita identificar a “vagueness” sem gerar explosão lógica ao recorrer à identificação do contexto (KB) dado pelo banco de dados.

Em suma, vale frisar e concluir, assim como a razão humana é limitada pela experiência sensível e pelas próprias estruturas mentais, uma IA é limitada pelo seu próprio algoritmo e banco de dados.

Outro ponto central para entender a limitação da inteligência artificial e a impossibilidade da Inteligência Artificial Geral está no próprio debate entre Russel e Frege sobre o que é a “verdade”. A única verdade que é cognoscível para uma IA está no processo de equivalência, conforme defendido por Russel. A IA tão somente pode atribuir valor verdade à proposições de acordo com a sua equivalência com o mundo real. Apesar

de uma IA poder atribuir valor verdade à uma estrutura lógica, o mundo real é um fenômeno inatingível para uma máquina digital. A verdade que uma IA é capaz de alcançar dependerá sempre da mediação da razão humana expressada na programação do seu algoritmo e no seu treinamento baseado em banco de dados de conhecimento humano.

Vale, aqui, lembrar da Crítica da Razão Pura de Kant para sintetizar meu argumento. Uma IA pode até ter proficiência sobre juízos analíticos puros (ou absolutamente *a priori*), mas, dependerá sempre da intervenção humana para lidar com juízos *a posteriori*, isto é, aqueles que dependem da experiência. Em suma, uma IA pode ser até superior a um humano em cálculos de matemática pura, mas, quando o assunto depende de diferenças específicas (no conceito de Aristóteles) de um ser humano, como em questões subjetivas, ela ou será incapaz de produzir conhecimento original, ou emulará um conhecimento original baseado no processamento (que lhe foi imposto por um programador) de um algoritmo.

Para sintetizar meu argumento numa linguagem de ciências exatas que os engenheiros que povoam a Passárgada do Vale do Silício consigam compreender sobre o porquê da IA jamais conseguir suplantar a inteligência humana: um algoritmo de IA é uma função limite, onde o limite é um problema não computável de cognição entre mundo digital e mundo real. E o mundo real só é cognoscível para uma máquina digital a partir de uma mediação proveniente do próprio mundo real. Prova disso está na necessidade de que o aprendizado de máquina, mesmo que só em seus estágios iniciais, seja feito por uma pessoa. Uma IA que programa a si mesma é uma contradição lógica. É a mesma coisa que, no exemplo usado anteriormente, um livro que escreve a si mesmo antes de ser lido por si mesmo para que com isso ensine a si mesmo o que ele mesmo escreveu sobre si mesmo.

Conclusão Intermediária

O que argumentei até aqui foi que o modelo de negócios das Big Techs está errado, à começar por limitações do sistema lógico utilizado para a criação das IAs – que resultam em alucinações, não obstante à própria limitação linguística de como opera um LLM.

Em defesa de um novo modelo de IA

Não sou ingênuo, caro leitor, a ponto de dizer que as IAs são inúteis. Apenas defendo que o modelo atual das IAs encontra limitações lógicas. As IAs, contudo, tem uma função essencial, qual seja, o de análise de quantidades gigantescas de dados. E é tendo esta função específica que eu proponho, doravante, um novo modelo de programação para as IAs. Ao contrário do que defendem os CEOs do Google e da OpenAI, IAs não adquirem consciência e nem irão substituir todo o trabalho humano. Tampouco são gurus da Verdade de nossos tempos. São, na verdade, ferramentas uteis para a análise de dados.

Se na primeira parte deste ensaio defendi que o sistema lógico que deve ser empregado em IAs é o de lógica paraconsistente e que o modelo atual alucina na maioria das vezes devido à limitação de cálculos de probabilidade de lógica clássica para predição de palavras; nesta segunda parte defenderei um sistema de programação para IAs que não se resume em meros cálculos estatísticos que não passam de emulação da linguagem humana.

Em resumo, para que o leitor não perca de vista o fio condutor, defendi na primeira parte que LLMs devem usar como sistema lógico para sua programação a lógica paraconsistente aliado à lógica clássica. Isso porque para sistemas não triviais, como num modelo de linguagem, é a única solução para que não se caia, necessariamente, em alucinações de máquina. Apontei, também, que LLMs baseado em meros cálculos matriciais de análise combinatória de probabilidade de predição da próxima palavra baseada na palavra anterior tem como resultado inevitável resultado as alucinações de máquina.

Ainda a partir da lógica paraconsistente argumentei que é necessário um sistema de refinamento do prompt antes que sejam aplicados cálculos estatísticos. E comecei a definir este sistema de refinamento a partir de uma estruturação através de silogismos científicos aristotélicos que considerem o paradoxo de Hempel, o paradoxo dos cisnes brancos e negros e que tenha como elemento norteador o princípio da falseabilidade. Tendo sempre em vista que o resultado do algoritmo de uma IA deve ser uma proposição cujo valor verdade seja determinada pelo grau de equivalência (apreendida pela IA através do treinamento por reforço) entre banco de dados e mundo real. E este valor verdade, por sua vez, deve ser determinado por graus relativos de valor verdade que não sejam

limitados por valores absolutos (absolutamente verdadeiro ou absolutamente falso, 0 ou 1), mas que permita valores verdade intermediários (lembro do exemplo da água morna).

Doravante continuo a explorar como deve ocorrer este refinamento das proposições, extraídas do prompt, a partir da lógica paraconsistente num LLM.

Como um leitor mais atento deve ter inferido, embora a forma de um silogismo científico aristotélico seja útil para estruturar o refinamento de uma proposição extraída de um prompt, por se tratar de lógica clássica, há o problema da trivialidade do sistema. Minha proposta para a solução da redução de um sistema de lógica clássica mediante uma contradição é o de que, embora se mantenha as regras gerais de um silogismo científico aristotélico, as premissas não devem ser estruturadas no clássico molde “S é P”, mas, de um refinado sistema de juízos, tal qual proposto por Immanuel Kant na Crítica da Faculdade do Juízo. Lembro a tabela de juízos kantianos:

1. Quantidade	Universais (Todos S)	Afirma ou nega sobre a totalidade.
	Particulares (Algum S)	Afirma ou nega sobre uma parte.
	Singulares (Este S)	Refere-se a um único indivíduo.
2. Qualidade	Afirmativos (S é P)	Conexão positiva entre sujeito e predicado.
	Negativos (S não é P)	Separação entre sujeito e predicado.
	Infinitos (S é não-P)	Limita o predicado, não apenas nega.
3. Relação	Categóricos (S é P)	Relação direta (absoluta) S-P.
	Hipotéticos (Se S, então P)	Relação de causa/efeito (condicional).

	Disjuntivos (A ou B ou C)	Relação de exclusão mútua (alternativa).
4.	Problemáticos (S pode ser P)	A afirmação/negação é mera possibilidade.
Modalidade		
	Assertóricos (S é P, fato)	A afirmação é real (a posteriori).
	Apodíticos (S deve ser P)	A afirmação é necessária (a priori).

Como um sistema de linguagem é um sistema não trivial, a tábua de juízos kantiana permite que haja o refinamento das proposições, e a proposta de valores verdade relativos entre “absolutamente verdadeiro” e “absolutamente falso” sem que haja uma explosão do sistema.

Vamos a um exemplo prático. Retomemos o exemplo da proposição “A água a 35 graus é quente ou fria?”. Na lógica clássica, num sistema de cálculo estatístico matricial de análise combinatória de predição de palavras à uma explosão do sistema porque o conceito de morno é um valor verdade intermediário entre os conceitos de “quente” e “morno”.

Num sistema paraconsistente, atribui-se o valor verdade de “verdadeiro” (0) ao conceito de quente e o valor verdade “falso” ao conceito de frio. Morno, na medida em que é um valor verdade intermediário entre quente e frio.

A solução que eu proponho para essa limitação dos modelos atuais é empregar a lógica difusa em modelos de IA ou LLMs para poderem admitir valores verdade intermediários entre dois conceitos opostos. Esta adoção do sistema fuzzy se daria por meio do sistema de Lógica Epistêmica para superar o problema de que “contradição = trivialização”

A minha proposta de adicionar uma tabela de juízos, na forma da tábua dos juízos da terceira crítica kantiana, é o início de uma solução para que um sistema paraconsistente (através de fuzzy) adquira a fórmula “contradição + consistência = trivialização” é o início de uma solução para que haja a aplicação da consistência num sistema não trivial de LLM.

A proposição “A água a 35 graus está quente ou fria?” precisa ser refinada em todas as seguintes hipóteses antes que seja feita a consulta por um modelo estatístico de equivalência entre proposição e banco de dados: Quantidade (universais, particulares, singulares), qualidade (afirmativos, negativos e infinitos), relação (Categóricos, hipotéticos, disjuntivos) e modalidade (Problemáticos, assertóricos e apodíticos).

Por exemplo:

Quantidade:

Universal: Toda água a 100 graus é quente; toda água a 0 graus é fria

Particular: Alguma água a 35 graus é quente ou fria

Singular: Esta água a 35 graus é morna (no caso do exemplo desta proposição proposta, esta será a resposta do prompt uma vez aplicado o modelo estatístico de equivalência entre proposição e banco de dados)

Qualidade:

Afirmativo: água a 35 graus é morna (resultado do prompt)

Negativo: água a 35 graus não é quente; água a 35 graus não é fria

Infinitos: Água a 35 graus é não fria; água a 35 graus é não quente

Relação:

Categóricos: Água entre 0 e 100 graus é morna

Hipotéticos: Se água entre 0 e 100 graus, então é morna

Disjuntivo: Água é quente ou fria ou morna dependendo do valor verdade que admite relativo e não apenas absoluto (0 ou 1)

Modalidade:

Problemático: Água a 35 graus pode ser morna? (forma do prompt proposto)

Assertórico: Água é morna por causa da temperatura

Apodícticos: Água deve ser morna porque está entre 0 e 100 graus

Lembro da síntese kantiana: "pensamentos sem conteúdo são vazios, intuições sem conceitos são cegas". O que temos até aqui são pensamentos – expressos na forma de proposição, conforme a teoria de Frege sobre a proposição) não são vazios porque são passíveis de atribuição de um valor verdade de lógica difusa.

O que nos falta é compreender como funciona uma intuição num sistema paraconsistente e como aplicar conceitos para que o sistema não se reduza à mera estatística.

Numa analogia, o equivalente ao que Kant chama de intuição sensível (empírica) será um valor verdade de equivalência entre proposição e mundo real. É como a IA recebe o conteúdo do banco de dados. É adquirida através do processo de aprendizagem de máquina. A intuição Pura (a priori) é a forma que o banco de dados está organizado na rede neural artificial. A síntese é o cálculo probabilístico que media a intuição sensível e a intuição pura. Em outras palavras, a síntese (a conclusão do prompt) é o resultado do grau de equivalência entre todos os juízos sobre um único prompt, acima ilustrados, e o banco de dados utilizado no treinamento da IA.

O que faz este modelo de IA e LLM não ser apenas cálculos de probabilidade? Ou sobre a vantagem de sistemas de LLM Neurais Híbridos.

Se parássemos a estruturação de um novo paradigma para IAs e LLMs seja um modelo distinto de todos os modelos propostos até aqui pelas Big Techs? Qual o ponto nevrálgico para que este modelo de IA não seja mero modelo de cálculo de probabilidades?

Está na criação do que eu chamarei de “tábua de conceitos” para LLMs e IAs generativas. É preciso criar algo fixo que possa ser usado como conceitos dos termos da proposição antes que se aplique o cálculo matricial de análise combinatória probabilística

de equivalência entre proposição (destrinchada conforme a tabela dos juízos) e banco de dados.

Imagine, caro leitor, que a linguagem é uma combinação de conceitos que foram proposições; que formam juízos. Os conceitos, para uma LLM, podem ser extraídos, por exemplo de um grande dicionário. Estes conceitos, por sua vez, lembrando de Aristóteles, mais uma vez, relacionam entre si, numa primeira etapa, através de “Homônimos”, “Sinônimos” e “Parônimos”.

Cabe ao aprendizado de máquina determinar a relação que estes conceitos assumem numa proposição de acordo com o contexto que é extraído do prompt e do banco de dados.

A criação de um sistema rígido de conceitos permite que a programação de uma LLM inicie num sistema de valor verdade binário antes de se aplicar a lógica paraconsistente; Esta ressalva, ao menos em teoria, evitaria alucinações na medida em que impediria que a relação entre conceitos seja dado por um cálculo estatístico de predição da próxima palavra com relação à palavra anterior.

O problema de um sistema de IA ou LLM puramente baseado em lógica difusa está no fato que, devido à própria natureza de sistemas digitais ser um sistema binário, sempre será necessário a conversão do valor difuso num valor binário. Quando há uma tábua de conceitos que determina as relações possíveis entre os conceitos de forma binária (determinada pelas relações de sinonímia, homonímia e paronímia) não é necessário que se chama em programação fuzzy de “Defuzzyficação”.

Não obstante, que o sistema de LLM seja construído com bases sólidas em conceitos bem determinados possibilita que o Grande Modelo de Linguagem não seja redutível à um sistema de complexos cálculos de probabilidade de predição das próximas palavras. Na verdade, o sistema que aqui é proposto é um sistema de aplicação de conceitos de acordo com o grau de equivalência entre proposição e banco de dados.

Conclusão

Meu objetivo neste artigo foi o de estabelecer limites para os atuais modelos das IAs das BigTechs e propor uma epistemologia para um sistema neural híbrido de LLM.

Da Aplicação Prática do Sistema de LLM defendido neste artigo

Abaixo segue um modelo de programação, por mim desenvolvido e em fase de registro de patente, de aplicação prática do que defendi neste artigo como sendo um novo modelo necessário para as IAs. E forneço um modelo para que o leitor tenha uma ideia prática de que o sistema neural híbrido aqui defendido é superior ao sistema atualmente utilizado pelas BigTechs e não me acuse de ficar apenas em conceitos abstratos e discussões conceituais, mas, para que o leitor possa ver como funciona o tipo de sistema aqui defendido na prática.

Abaixo segue o pipeline do Modelo de IA por mim desenvolvido que emprega, na prática, o que defendi acima. Eu batizei este modelo de prova conceitual de IA Doninha. Vale notar que nos benchmarks executados, o resultado foi superior ao dos modelos das Bigtechs.

TÍTULO DA INVENÇÃO

MÉTODO E SISTEMA DE MIDDLEWARE TRANSPARENTE DE RACIOCÍNIO EPISTEMOLÓGICO EM MÚLTIPLAS CAMADAS PARA INTERCEPTAÇÃO, PROCESSAMENTO E ENRIQUECIMENTO BIDIRECIONAL DE CHAMADAS ENTRE APLICAÇÕES CLIENTE E MODELOS DE LINGUAGEM DE GRANDE ESCALA EXTERNOS — IA DONINHA.

CAMPO DA INVENÇÃO

A presente invenção pertence ao campo da arquitetura de software, processamento de linguagem natural (PLN) e inteligência artificial. Refere-se especificamente a um método e sistema de middleware transparente — camada intermediária de software interposta entre um usuário ou aplicação cliente e um modelo de linguagem de grande escala (LLM) externo (como GPT, Claude, Gemini ou equivalentes) — que intercepta chamadas de entrada e saída, aplica um pipeline de raciocínio epistemológico estruturado em múltiplas camadas funcionalmente distintas, e devolve ao LLM externo prompts enriquecidos com

proposições hierarquizadas, graus de verdade quantificados e verificação interna de consistência lógica, sem requerer modificação da aplicação cliente nem do LLM externo.

ANTECEDENTES DA INVENÇÃO

Os modelos de linguagem de grande escala (LLMs) disponíveis comercialmente — incluindo, sem limitação, modelos baseados em arquitetura Transformer como GPT (OpenAI), Claude (Anthropic), Gemini (Google) e equivalentes — são acessados por aplicações cliente mediante chamadas a APIs padronizadas (geralmente HTTP/REST ou WebSocket), nas quais o cliente envia um prompt em linguagem natural e recebe uma resposta gerada pelo modelo.

Esse modelo de integração apresenta as seguintes limitações estruturais documentadas na literatura técnica e científica:

- Ausência de pré-processamento epistêmico: o prompt é enviado ao LLM exatamente como formulado pelo usuário, sem decomposição formal em conceitos, hipóteses ou juízos, resultando em respostas que refletem diretamente os vieses e ambiguidades da entrada.
- Inexistência de quantificação de incerteza na entrada: o LLM externo não recebe informações sobre o grau de certeza, contradição ou indeterminação das proposições contidas no prompt, impossibilitando calibração epistêmica da resposta.
- Ausência de verificação de consistência pré-geração: contradições lógicas presentes no prompt são transmitidas integralmente ao LLM, que as processa sem mecanismo formal de detecção ou tratamento.
- Opacidade do raciocínio intermediário: o processo de transformação entre prompt e resposta ocorre inteiramente no interior do LLM externo, sem etapa auditável de raciocínio intermediário acessível à aplicação cliente.
- Dependência de engenharia de prompt manual: a qualidade da resposta depende inteiramente da habilidade do usuário em formular prompts adequados, sem camada automatizada de refinamento estrutural.

Soluções anteriores, como sistemas de prompt engineering automatizado, guardrails de saída e wrappers de API, atuam predominantemente no pós-processamento da resposta ou na filtragem superficial do prompt, sem implementar raciocínio epistemológico estruturado na camada de interceptação. A IA Doninha preenche essa lacuna com uma solução de middleware transparente original, que opera na camada de interceptação bidirecional sem exigir modificações na aplicação cliente ou no LLM externo.

SUMÁRIO DA INVENÇÃO

A invenção provê um método e sistema de middleware transparente implementado em computador, interposto na camada de comunicação entre uma aplicação cliente (usuário) e um modelo de linguagem de grande escala (LLM) externo, compreendendo:

- Interceptação transparente de chamadas de entrada: o middleware recebe o prompt originado pela aplicação cliente antes de sua transmissão ao LLM externo, sem que a aplicação cliente necessite conhecer ou modificar seu comportamento de chamada.
- Pipeline de raciocínio epistemológico em sete camadas (L1–L7): processamento estruturado do prompt interceptado por camadas funcionalmente distintas de extração conceitual, classificação kantiana de juízos, avaliação paraconsistente, síntese russelliana e verificação por Chain of Verification.
- Enriquecimento do prompt: o prompt original é substituído ou aumentado por um prompt enriquecido, contendo proposições hierarquizadas por prioridade epistêmica, graus de verdade quantificados e instruções de calibração para o LLM externo.
- Interceptação e pós-processamento da resposta: a resposta gerada pelo LLM externo é interceptada pelo middleware antes de ser devolvida à aplicação cliente, podendo ser anotada com metadados epistêmicos (grau de certeza, estado paraconsistente, log de verificação).
- Operação transparente bidirecional: do ponto de vista da aplicação cliente e do LLM externo, a presença do middleware é imperceptível — a aplicação cliente

envia e recebe no mesmo formato de sempre; o LLM externo recebe e responde a chamadas de API padrão.

DESCRIÇÃO DETALHADA DA INVENÇÃO

Arquitetura de Middleware Transparente

O sistema IA Doninha, na modalidade de middleware transparente, é implementado como um processo intermediário que se posiciona na pilha de comunicação entre a aplicação cliente e o LLM externo. A operação do middleware compreende dois planos de intercepção:

Plano de entrada (upstream): intercepta o prompt antes de sua transmissão ao LLM externo. O prompt original é capturado, processado pelo pipeline epistemológico L1–L7, e o resultado enriquecido é transmitido ao LLM externo em substituição ao prompt original, no mesmo formato de chamada esperado pelo LLM (ex: campo "messages" de uma chamada à API OpenAI-compatible).

Plano de saída (downstream): intercepta a resposta gerada pelo LLM externo antes de sua entrega à aplicação cliente. A resposta é opcionalmente anotada com metadados epistêmicos produzidos pelo pipeline (grau de verdade $v \in [0,1]$, estado paraconsistente, grau de certeza G_c , grau de contradição G_{ct} , log de verificação CoVe) e devolvida à aplicação cliente no formato original de resposta da API.

A transparência é garantida por dois mecanismos: (i) o middleware implementa a mesma interface de entrada e saída do LLM externo alvo, de modo que a aplicação cliente não requer alteração de código; (ii) o middleware encaminha as chamadas ao LLM externo utilizando as credenciais e endpoints configurados, atuando como proxy epistêmico.

5.2. Fluxo de Processamento Bidirecional

O fluxo completo de processamento, para cada chamada interceptada, compreende as seguintes etapas em sequência:

- Etapa 1 — Recepção: o middleware recebe a chamada da aplicação cliente contendo o prompt em linguagem natural.
- Etapa 2 — Extração conceitual (L1): identificação e mapeamento de termos do prompt a relações semânticas binárias (sinonímia, antonímia, hiponímia, hiperonímia, homonímia, paronímia) segundo categorias aristotélicas, com filtragem de conceitos contextualmente incompatíveis pelo módulo LogicLM Symbolic Solver.
- Etapa 3 — Classificação kantiana (L2): classificação do prompt nas doze categorias da Tábua dos Juízos de Kant (Quantidade $\times$ Qualidade $\times$ Relação $\times$ Modalidade), geração de hipóteses com pesos de prioridade e classificação epistêmica tridimensional (T, I, F) sem restrição de soma unitária.
- Etapa 4 — Avaliação paraconsistente (L3): atribuição de pares de anotações (μ, λ) — graus de evidência favorável e contrária — a cada hipótese, segundo a Lógica Anotada de Evidências (LAE/PAL2v); cálculo de grau de certeza $G_c = \mu - \lambda$ e grau de contradição $G_{ct} = \mu + \lambda - 1$; determinação de estado qualitativo no reticulado paraconsistente (Verdadeiro, Falso, Inconsistente_local, Indeterminado, Intermediário); tratamento de contradições locais por explosão gentil sem trivialização global.
- Etapa 5 — Síntese russelliana (L4): ponderação das hipóteses por correspondência entre proposições e fatos do banco de conhecimento (equivalência russelliana); aplicação do agente de Chain of Verification (CoVe — variante Factor + Revise) para verificação interna; cálculo do valor-verdade final ponderado $v_final \in [0,1]$.
- Etapa 6 — Construção do prompt enriquecido (L5): o prompt original é transformado em prompt estruturado contendo: (a) proposições hierarquizadas por prioridade epistêmica; (b) graus de verdade e certeza calculados; (c) instruções de calibração epistêmica para o LLM externo; (d) metadados de estado paraconsistente.
- Etapa 7 — Transmissão ao LLM externo: o prompt enriquecido é transmitido ao LLM externo via chamada de API padrão.

- Etapa 8 — Interceptação da resposta (L6–L7): a resposta do LLM externo é interceptada, opcionalmente refinada e anotada com metadados epistêmicos pelo pipeline de geração final.
- Etapa 9 — Entrega à aplicação cliente: a resposta (com ou sem anotações epistêmicas, conforme configuração) é entregue à aplicação cliente no formato padrão de resposta da API.

5.3. Pipeline Epistemológico L1–L7

O pipeline de raciocínio epistemológico que opera internamente ao middleware compreende sete camadas funcionalmente distintas, descritas a seguir:

L1 — Tábua de Conceitos: extração formal de conceitos por relações semânticas binárias segundo categorias aristotélicas; verificação de compatibilidade canônica pelo módulo LogicLM Symbolic Solver; enriquecimento com contexto de domínio a partir da base de conhecimento (KB).

L2 — Juízos Kantianos: classificação nas doze categorias da Tábua dos Juízos de Immanuel Kant; geração de hipóteses com pesos de prioridade (Juízo Singular Afirmativo Assertórico = prioridade máxima 1.0); classificação epistêmica tridimensional (T, I, F) por EpistemicClassification.

L3 — Avaliação Paraconsistente: implementação da Lógica Anotada de Evidências (LAE/PAL2v) de da Costa e Abe; atribuição de anotações (μ , λ); cálculo de Gc e Gct; determinação de estado qualitativo; roteamento fuzzy de pares de proposições por ManyValuedRouter; verificação de consistência global (ausência de trivialização).

L4 — Síntese Russelliana: ponderação por equivalência entre proposições e fatos do KB segundo a teoria da verdade como correspondência de Bertrand Russell; base russelliana de conceitos extraída de corpus filosófico; Chain of Verification (CoVe — Factor + Revise) com geração de perguntas de verificação, avaliação independente e revisão da síntese; cálculo de v_{final} ponderado.

L5 — Geração estruturada: construção do prompt enriquecido a partir da síntese L4; suporte a múltiplos provedores de LLM para geração auxiliar (Groq, Ollama, modelo customizado ou template interno).

L6 — Refinamento epistêmico: agente escritor para refinamento da resposta com calibração adaptativa ao grau de certeza calculado; introduções e conclusões adaptativas ao estado paraconsistente.

L7 — Texto final: produção do texto final com classificação de audiência (leigo, técnico, acadêmico) e adaptação de estilo, terminologia e nível de formalismo; verificação de alertas de incompatibilidade canônica gerados na L1.

5.4. Base de Conhecimento e Módulo RAG

O middleware mantém internamente uma base de conhecimento (knowledge base — KB) estruturada como dicionário $\{\text{termo} \rightarrow \text{grau_de_evidência} \in [0,1]\}$, utilizada pelas camadas L1–L4 para cálculo de graus de correspondência e anotações paraconsistentes. A KB é escalável e pode ser enriquecida dinamicamente por módulo opcional de Retrieval-Augmented Generation (RAG), que recupera evidências relevantes a partir de bases documentais externas em tempo de interceptação, aumentando a precisão das anotações (μ, λ) para o domínio específico da consulta interceptada.

5.5. Modos de Operação

Modo heurístico: os graus de anotação paraconsistente (μ, λ) são calculados exclusivamente a partir da KB e de detecção de pares antonímicos. Operação sem dependência de modelos neurais externos. Adequado para ambientes com restrições de latência.

Modo neural: os graus (μ, λ) são calculados por modelo neural de pontuação de verdade (TruthScoringModel) baseado em arquitetura de atenção multilingual (BERT multilingual), modulados pela prioridade kantiana L2. Maior precisão epistêmica a custo de latência adicional.

Modo com RAG: a KB é enriquecida em tempo de interceptação por recuperação de evidências em bases documentais externas, permitindo operação em domínios especializados não cobertos pela KB estática.

5.6. Transparência e Compatibilidade

A transparência do middleware é garantida pelos seguintes mecanismos técnicos: (i) implementação de interface de entrada compatível com o protocolo de chamada do LLM externo alvo (ex: OpenAI Chat Completions API, Anthropic Messages API, Google Generative AI API), de modo que a aplicação cliente não requer alteração de endpoint, autenticação ou formato de requisição; (ii) encaminhamento das chamadas enriquecidas ao LLM externo com as credenciais e endpoints originalmente configurados pela aplicação cliente; (iii) devolução da resposta no formato padrão esperado pela aplicação cliente, com metadados epistêmicos opcionalmente encapsulados em campo adicional não-disruptivo (ex: campo "doninha_metadata" no corpo JSON da resposta).